

HW-01

ДЗ-01. Стратегия, оценка рисков и дорожная карта AI-проекта

Проект «Интеллектуальная система рекомендаций» для Techno-Mart

1. Анализ требований — уточняющие вопросы

Бриф TechnoMart содержит ряд «серых зон», без прояснения которых невозможно адекватно оценить ни бюджет, ни сроки, ни архитектуру. Ниже — семь ключевых вопросов, сгруппированных по категориям скрытых требований. Каждый вопрос нацелен на конкретный риск, а не задан «для галочки».

1.1. Данные и их доступность

Вопрос 1. Какие исторические данные о поведении пользователей доступны, и за какой период?

Сейчас клики и просмотры уходят в Google Analytics, а сырых логов на собственных серверах почти нет. Рекомендательная модель обучается на истории взаимодействий — без неё мы работаем вслепую. Нам нужно понять: есть ли возможность выгрузить хотя бы агрегированные данные из GA за последние 6-12 месяцев? Готов ли заказчик оперативно развернуть сбор событий (event-трекинг) на своей стороне?

Зачем спрашиваем: от ответа зависит длительность этапа подготовки данных (data discovery) — это самая непредсказуемая часть AI-проекта. Если данных нет совсем, PoC растягивается, а бюджет на подготовку данных может превысить бюджет на саму модель.

Вопрос 2. Как устроена идентификация пользователя в офлайне и онлайн?

Бриф требует омниканальности: если клиент купил телевизор в магазине, сайт не должен предлагать его повторно. Но как именно связываются офлайн-покупки с онлайн-профилем? Есть ли единый идентификатор клиента (карта лояльности, номер телефона)? Какой процент покупателей идентифицирован в обоих каналах?

Зачем спрашиваем: без сквозной идентификации омниканальные рекомендации невозможны технически. Если идентификация покрывает лишь 10% аудитории, эту фичу стоит отложить на стадию масштабирования (Scale), а не закладывать в MVP.

1.2. Безопасность и регуляторика

Вопрос 3. Каковы ограничения по контуру обработки персональных данных (ПДн)?

TechnoMart работает с ФИО, телефонами, адресами — это ПДн по ФЗ-152. Бизнес хочет использовать LLM для генерации описаний. Ключевой вопрос: допустима ли обработка данных в российском публичном облаке (Яндекс Cloud, Cloud.ru), или требуется размещение строго на собственных серверах (on-prem)? Есть ли у TechnoMart заключение или позиция службы информационной безопасности по этому вопросу?

Зачем спрашиваем: ответ определяет архитектуру LLM-компонента: облачный API (дёшево, быстро) либо self-hosted модель (дорого, долго разворачивать, нужны GPU). Это прямое влияние на бюджет и сроки.

1.3. Производительность и технические ограничения

Вопрос 4. Требование «200 мс» — это время полной загрузки блока рекомендаций или только серверное время ответа (TTFB)?

200 мс — жёсткое ограничение, которое определяет, можно ли вызывать LLM в реальном времени (спойлер: скорее всего, нет). Нужно уточнить, входит ли сюда время рендеринга на фронтенде, сетевые задержки, или речь только о серверной части.

Зачем спрашиваем: если 200 мс — это чистое серверное время, генеративные описания придётся предвычислять заранее (в пакетном режиме), а не генерировать на лету. Это принципиально меняет архитектуру и пользовательский опыт.

1.4. Интеграция и команда

Вопрос 5. Какие изменения в монолите на Bitrix допустимы? Есть ли возможность вызова внешнего API из текущего кода?

СТО настаивает: «ничего не переписывать в ядре». Но рекомендательный блок должен как-то появиться на страницах сайта. Нам нужно понять границы допустимого: можно ли добавить JavaScript-виджет, обращающийся к отдельному сервису? Есть ли уже практика подключения внешних микросервисов? Готов ли СТО к тому, что рекомендательный сервис будет работать вне Bitrix как самостоятельный компонент?

Зачем спрашиваем: архитектура интеграции — один из главных технических рисков. Если монолит полностью закрыт для любых изменений, нам придётся работать через прокси-слой или JavaScript-инъекцию, что увеличивает сложность и сроки.

Вопрос 6. Планирует ли TechnoMart нанимать собственных специалистов по данным (Data Scientists, ML-инженеров) или предполагает полную передачу эксплуатации подрядчику?

Сейчас у заказчика нет ни DS, ни DE. AI-система — это не «поставил и забыл»: модели деградируют, данные дрейфуют, метрики нужно отслеживать. Кто будет этим заниматься после сдачи проекта?

Зачем спрашиваем: ответ определяет, нужен ли контракт на сопровождение (retainer), объём документации и обучения, а также глубину автоматизации MLOps-процессов — чем меньше компетенций у заказчика, тем больше нужно автоматизировать.

1.5. Критерии успеха

Вопрос 7. Какой целевой показатель конверсии блока рекомендаций считается успехом проекта? Есть ли у бизнеса порог, ниже которого проект признаётся неудачным?

Текущая конверсия — 0.5%, среднерыночная — существенно выше. Но бриф не фиксирует целевую метрику. Без явного числа мы рискуем попасть в ловушку «мне не нравится, как работает» — бесконечное улучшение без точки приёма.

Зачем спрашиваем: целевая метрика ляжет в основу критериев приёма (Definition of Done) для каждого этапа и станет частью контракта. Это защищает и заказчика (гарантия результата), и исполнителя (фиксированная точка сдачи).

2. Выбор контрактной модели

Анализ ситуации

Проект TechnoMart содержит одновременно два потока работы:

- **Инженерный** (детерминированный): развернуть event-трекинг, создать микросервис рекомендаций, интегрировать с Bitrix. Эти задачи оцениваются в часах, результат предсказуем.
- **Исследовательский** (стохастический): подобрать модель рекомендаций, настроить генерацию описаний на LLM, добиться целевых метрик качества. Результат эксперимента заранее не гарантирован.

Фиксированная цена (Fixed Price) на всё целиком — это приглашение к конфликту: команда зависит оценку в 3 раза «на всякий случай», либо начнёт срезать углы на

качестве. Вместо этого предлагаем поэтапную контрактную схему, где тип контракта соответствует уровню неопределённости.

Рекомендуемая схема

Этап	Контракт	Обоснование
PoC (6 недель)	T&M (оплата по факту)	Максимальная неопределённость: данных не видели, гипотеза не проверена. Платим за эксперимент и отчёт, а не за готовый продукт. Отрицательный результат PoC — это не потеря денег, а экономия на несостоявшейся разработке.
MVP (10 недель)	Capped T&M (оплата по факту с потолком бюджета)	Неопределённость снижена после PoC: score понятен, данные изучены. Потолок бюджета успокаивает финансового директора, а оплата по факту оставляет гибкость для итераций. Дополнительно: бонус команде за превышение целевой метрики конверсии — это мотивирует делать качественно, а не просто «сдать».
Production (3+ мес.)	Гибрид: FP на конкретные фичи + T&M retainer на поддержку	Требования стабилизированы, технология доказана на MVP. Отдельные доработки (пуш-рассылки, омниканальность) можно контрактовать по фиксу. Текущая поддержка и развитие — абонентская плата (retainer).

Аргументация для стейкхолдеров

Для CEO (язык ROI и времени выхода на рынок):

«Поэтапная схема позволяет увидеть первый результат через 6 недель, а не через 6 месяцев. Если PoC покажет, что гипотеза не работает, мы потеряем максимум бюджет одного этапа — это страховка, а не расход. При фикс-прайсе на всё сразу цена вырастет втрое из-за закладки рисков, а гибкости поменять курс не будет вовсе.»

Для СТО (язык технических рисков):

«Т&М на PoC означает, что мы не будем спешить ради дедлайна и срезать углы: ни на безопасности (ФЗ-152), ни на интеграции с Bitrix. Мы сначала разберёмся с данными и докажем, что модель работает на ваших реальных данных, и только потом начнём встраивать в продакшен. Монолит не пострадает — рекомендательный сервис будет работать как отдельный компонент.»

3. Матрица рисков

Методология

Каждый риск оценён по двум осям: **вероятность** (1 — маловероятно, 5 — почти наверняка) и **влияние** (1 — незначительное, 5 — критическое). Произведение даёт **величину риска** (Risk Exposure). Для каждого риска указана стратегия работы по классификации: избежать (Avoid), снизить (Mitigate), передать (Transfer) или принять (Accept).

Таблица рисков

#	Риск	Категория	Вероятность (1-5)	Влияние (1-5)	Exposure (1-5)	Стратегия	План митигации
R1	Недостаток и низкое качество данных. Сырых логов поведения нет, каталог обновляется раз в сутки, чеки синхронизируются раз в 15 минут. Модель не на чем обучать.	Данные	4	5	20	Mitigate	Первые 2 недели PoC — data discovery и развёртывание event-трекинга (Яндекс Метрика / собственный коллектор). Параллельно — выгрузка агрегатов из GA за 6-12 мес. Если данных критически мало, использовать cold-start стратегии (популярные товары, контентная фильтрация).
R2	Утечка персональных данных через публичную LLM. ФИО, телефоны, адреса попадают в API внешней нейросети — нарушение ФЗ-152, репутационный ущерб.	Безопасность / Право	3	5	15	Avoid	Не отправлять ПДн в публичные LLM-сервисы. Для генерации описаний использовать self-hosted модель в приватном облаке (или on-prem). На входе в LLM-пайплайн — обязательная PII-санитизация: имена и контакты заменяются на плейсхолдеры, персонализация добавляется после генерации.
R3	Невозможность уложиться в 200 мс на инференсе DSIM LLM-генерации в реальном времени. Даже быстрые нейросети,	Модель / Инфра	5	4	20	Mitigate	Генеративные описания предвычислять в пакетном режиме (batch). Для инференса использовать гибридные (сервис + локальный) комбинации (например, OpenAI GPT-4o для «пользовательский сегмент + подборка»): Авто-выборка серв-
R4	Инфраструктурный Org DSIM LLM-генерации в реальном времени. Даже быстрые нейросети,	Инфраструктура / Org	3	3	18	Transfer / Mitigate	Transfer / Mitigate

Тепловая карта

Влияние →	1	2	3	4	5
Вероятн.					
5			R3		
4		R4, R7	R5	R1	
3		R8	R6	R2	
2					
1					


Критическая зона (Exposure ≥ 15): **R1** (данные), **R2** (ПДн), **R3** (латентность), **R5** (галлюцинации) — требуют немедленного внимания и проработки на PoC.

4. Дорожная карта (Roadmap)

Общая логика

Совет директоров хочет увидеть результат через 3 месяца. Честный ответ: за 3 месяца можно показать работающий пилот (MVP) на ограниченной аудитории, но не промышленную систему на 100% трафика. Стратегия — «покажем ценность быстро, масштабируем уверенно»:

- **PoC** (недели 1-6) — доказать, что ML-модель лучше текущих правил
- **MVP** (недели 7-16) — пилот на реальных пользователях, A/B-тест
- **Production** (месяцы 5-8) — раскатка на весь трафик, надёжность, масштаб



Этап 1. PoC — проверка техгипотезы (недели 1-6)

Цель: доказать, что ML-модель рекомендаций на данных TechnoMart превосходит текущую rule-based систему по офлайн-метрикам, а генерация описаний технически реализуема без утечки ПДн.

Контракт: T&M.

Активности:

Неделя	Задача	Результат
1-2	Исследование данных (data discovery): аудит источников, выгрузка из GA, анализ чеков из 1С, оценка качества	Отчёт о состоянии данных, перечень «дыр» и план их закрытия
2-3	Развёртывание event-трекинга на сайте (клики, просмотры, добавления в корзину)	Поток событий в реальном времени
3-5	Исследовательский анализ (EDA), построение базовой модели (collaborative filtering или ALS), сравнение с rule-based baseline	Офлайн-метрики: precision@10, recall@10, NDCG
4-6	Прототип генерации описаний на LLM в пакетном режиме с PII-санитизацией	Примеры сгенерированных описаний, оценка качества (ручная + LLM-as-judge)

Критерии завершения (Definition of Done):

1. ML-модель превосходит rule-based baseline минимум на 30% по precision@10 на офлайн-тесте
2. Подготовлен отчёт об эксперименте: что сработало, что нет, какие данные критичны
3. Подтверждена возможность генерации описаний без отправки ПДн вовне
4. Сформирован уточнённый score и оценка трудозатрат для MVP
5. Принято решение **GO/NO-GO** — продолжаем или останавливаемся

Что обещаем заказчику: только отчёт об эксперименте. Не демо-версию, не прототип для показа клиентам — отчёт с цифрами и рекомендациями.

Этап 2. MVP — пилот на реальных пользователях (недели 7-16)

Цель: запустить персонализированные рекомендации на 10% трафика сайта, провести A/B-тест и доказать рост конверсии по сравнению со старой системой.

Контракт: Carped T&M (потолок фиксируется по результатам оценки после PoC).
Бонус команде при достижении конверсии блока рекомендаций $\geq 2\%$.

Активности:

Неделя	Задача	Результат
7-10	Разработка микросервиса рекомендаций (API: входные параметры — идентификатор пользователя/сессии, выходные — список товаров + описания)	Развёрнутый сервис в облаке, документация API
9-11	Интеграция с Bitrix: JavaScript-виджет на фронтенде, асинхронная загрузка рекомендаций через API, без изменений в ядре	Блок рекомендаций на страницах каталога и карточки товара
10-12	Пакетная генерация LLM-описаний для топ-комбинаций «сегмент + подборка», семантический кэш	Предвычисленные описания в хранилище, время отдачи < 50 мс
12-16	A/B-тест: 10% трафика получают AI-рекомендации, 90% — старую систему. Сбор метрик: конверсия, CTR блока, средний чек	Статистически значимые результаты A/B-теста

Критерии завершения (Definition of Done):

1. Конверсия блока рекомендаций на тестовой группе $\geq 1.5\%$ (рост минимум в 3 раза относительно текущих 0.5%)
2. Задержка ответа рекомендательного сервиса ≤ 200 мс (p95)
3. Ни один запрос с ПДн не покидает защищённый контур — подтверждено аудитом логов

4. A/B-тест статистически значим ($p\text{-value} < 0.05$, минимум 2 недели наблюдения)
5. Бизнес-заказчик подтверждает: «да, это то, чем мы хотим пользоваться»

Что показываем совету директоров через 3 месяца: работающий пилот на 10% трафика с измеримым ростом конверсии. Это не полноценный продукт, но это реальные цифры, на которых можно принять решение о масштабировании.

Этап 3. Production — масштабирование и надёжность (месяцы 5-8)

Цель: раскатить рекомендации на 100% трафика, обеспечить промышленную надёжность, запустить омниканальные сценарии и пуш-рассылки.

Контракт: гибрид — Fixed Price на конкретные доработки + T&M retainer на сопровождение и развитие.

Активности:

Месяц	Задача	Результат
5	CI/CD-конвейер, мониторинг и алертинг (метрики модели, SLA сервиса, стоимость запроса), автоматический retraining	Промышленная инфраструктура эксплуатации
5-6	Постепенная раскатка на 100% трафика (canary deployment: 10% → 30% → 60% → 100%)	Полный охват аудитории
6-7	Омниканальная идентификация: связка офлайн-покупок с онлайн-профилем через карту лояльности / телефон	Единый профиль клиента для рекомендаций
7-8	Пуш-уведомления и email-рассылки с AI-рекомендациями, персонализация главной страницы	Маркетинговые каналы с AI-контентом

Критерии завершения (Definition of Done):

1. Доступность сервиса (uptime) $\geq 99.5\%$ за последний месяц
2. Средний чек (AOV) вырос на $\geq 10\%$ по сравнению с периодом до внедрения — целевой KPI бизнеса
3. Стоимость рекомендации на одного пользователя рассчитана и укладывается в экономику (FinOps)
4. Автоматический retraining работает, алерты при деградации настроены
5. ADR (записи архитектурных решений) зафиксированы и согласованы с СТО
6. Документация по эксплуатации передана команде TechnoMart (или запущен re-tainer-контракт)

Сводная таблица Roadmap

Параметр	PoC	MVP	Production
Срок	6 недель	10 недель	3+ месяца
Контракт	T&M	Capped T&M + бонус	FP (фичи) + T&M (retainer)
Аудитория	Нет (офлайн-тест)	10% трафика	100% трафика
Ключевой вопрос	Возможно ли технически?	Нужно ли пользователю?	Стабильно и масштабируемо?
Ключевая метрика	precision@10 vs baseline	Конверсия блока $\geq 1.5\%$	AOV +10%, uptime 99.5%
Результат	Отчёт GO/NO-GO	Работающий пилот	Промышленная система
Риск при отмене	Потеря 1-2 млн (экономия 10+)	Потеря 5-8 млн	—

Заключение

Проект TechnoMart — классический AI-кейс с высокой начальной неопределённостью: нет данных, нет DS-команды, бизнес хочет «магию за 3

месяца». Стратегия «быстро проверить — показать ценность — масштабировать» позволяет:

- **Снизить финансовый риск:** PoC стоит условный миллион, а не десять. Отрицательный результат — это экономия, не потеря.
- **Управлять ожиданиями:** CEO получает результат через 3 месяца (пилот с цифрами), CTO уверен, что монолит не пострадает.
- **Выстроить доверие:** поэтапный контракт с прозрачной отчётностью — обе стороны видят, за что платят и что получают.

Главное правило: не начинать писать код, пока не договорились, как измерять успех и кто платит за ошибки.