

HW-02


Главное техническое противоречие проекта — требование выдавать рекомендации за 200 мс при желании бизнеса использовать LLM для «умных» рекомендаций. В онлайн-режиме это несовместимо: если запускать тяжелое ранжирование и генерацию текста в момент запроса, SLA будет нарушен. Поэтому онлайн-контур должен только читать уже готовый результат, а тяжелая обработка должна выполняться асинхронно.

Полноценный AI-контур с LLM, зрелым MLOps и омниканальностью нереалистично считать MVP на 3 месяца. У заказчика перегруженный монолит Bitrix/MySQL, собственных сырых логов почти нет, поведение в основном находится в Google Analytics, а отдельной команды Data Scientists / Data Engineers нет.

Поэтому с заказчиком был согласован компромисс: в MVP идем не в LLM-first сценарий, а в behavioral recommender, параллельно начиная сбор собственных сырых событий и формирование минимального feature layer для будущего ML-контура. LLM сознательно откладывается на следующий этап: она может улучшить объяснение рекомендаций, но не решает ключевую задачу — подбор и ранжирование SKU. Это дает заказчику понятный ML-вектор, не ломает сайт и создает фундамент для последующего развития.

Ниже — **C4 L2** и **C4 L3**: контейнерная диаграмма системы и компонентная диаграмма одного контейнера.


C4 L2 — Container Diagram



SWG PUML ### Описание контейнеров

- **Recommendation API** — online-вход в систему; быстро возвращает уже готовую выдачу.
- **Event Collector** — собирает новые события поведения с сайта.
- **Behavior Store** — хранит сырые события и простые агрегаты/признаки для MVP.
- **Behavioral Recommender Pipeline** — batch-контур, где строится behavioral recommender.
- **Recommendation Store** — low-latency хранилище предрасчитанных рекомендаций.

C4 L3 — Component Diagram для Behavioral Recommender Pipeline




SWG PUML

Описание компонентов

- **Data Importer** — подтягивает в единый контур историю поведения, покупки и каталог.
- **Profile & Feature Builder** — собирает минимальный feature layer MVP.
- **Candidate Generator** — формирует кандидатов для каждого профиля.
- **Behavioral Ranker** — считает скор и строит итоговый ranking.
- **Recommendation Publisher** — выгружает готовые рекомендации в serving-store для online API.

Sequence Diagram



SWG PUBL

OpenAPI 3.0 — /get_recommendation

Ниже представлена спецификация для взаимодействия между сайтом и AI Service. Она покрывает основной happy path, fallback и ошибки.

openapi-recommendation-api.yaml

Описание endpoint-ов

- POST /get_recommendation — основной контракт между сайтом и AI Service.
-
- API возвращает **готовый ranked SKU list**, а не инициирует online-обучение или вызов LLM.
- При отсутствии персональной выдачи сервис возвращает **fallback**.