

HW-04

ДЗ-04. ADR: где hostить LLM — облачная SaaS-модель или self-hosted Llama 3

Проект «Интеллектуальная система рекомендаций» для Techno-Mart

В HW-01 LLM-слой был сознательно отложен (риски R2 «утечка ПДн» и R3 «латентность»). Сейчас, на входе в фазу Scale, бизнес возвращается к идее «умных» описаний и объяснений рекомендаций на базе LLM. Нужно зафиксировать ключевое решение: **где и как hostить языковую модель**.

1. Сравнение вариантов по критериям

Рассматриваем два полюса: проприетарная облачная модель как сервис (SaaS, например GPT-класса через API) и self-hosted open-source модель (Llama 3 70B на арендованных/собственных GPU).

Критерий	Cloud (проприетарный API)	SaaS	Self-hosted Llama 3 (open-source)
Стоимость	Нет CapEx, оплата за токены. Дёшево на старте и при малом объёме, но при росте трафика расходы растут линейно и непредсказуемо (OpEx).	Высокий CapEx/фикс за GPU (аренда A100/L4), но OpEx за GPU (аренда A100/L4), но предсказуемая стоимость за запрос при стабильной нагрузке. На объёме дешевле.	
Privacy / безопасность (ФЗ-152)	ПДн (ФИО, телефоны, адреса) уходят во внешний, часто зарубежный сервис — прямое нарушение ФЗ-152 и риск R2. Контур обработки неподконтролен.	Данные не покидают доверенный контур (РФ-облако / on-prem). Полный контроль над контуром ПДн.	
Качество ответов	Выше «из коробки»: топовые проприетарные модели сильнее в генерации текста на русском и follow-instructions.	Llama 3 70B достаточна для шаблонно-генеративных описаний товаров; для нашей узкой задачи разрыв в качестве не критичен.	
Latency	Сетевой round-trip до внешнего API + очередь провайдера; нестабильный «хвост» р99. Под 200 мс online всё равно не вписывается.	Инференс рядом с сервисом, контролируемый р99. Всё равно работаем в batch/предвычислении, поэтому абсолютная задержка вторична.	
Сложность поддержки	Минимальная: нет GPU, нет MLOps для инференса. Идеально при отсутствии DS/DE команды (риск R7).	Высокая: нужен sizing GPU, vLLM/квантование, мониторинг, обновления. Требуется компетенций, которых у TechnoMart нет.	

Вывод из таблицы: критерии **Privacy** и **Сложность поддержки** тянут в разные стороны. Privacy/ФЗ-152 категорически запрещает отправлять ПДн в публичный

SaaS, а отсутствие команды делает «чистый self-hosted» дорогим и рискованным в поддержке.

2. Решение

Выбираем **гибридный подход с приоритетом self-hosted для любого контура, где присутствуют ПДн**:

1. Вся генерация, на вход которой потенциально попадают ПДн, выполняется **self-hosted Llama 3** в доверенном контуре (российское приватное облако с GPU, с опцией переезда on-prem).
 2. Перед любым вызовом модели работает **PII Sanitizer**: ФИО/телефоны/адреса заменяются на плейсхолдеры, персонализация добавляется уже после генерации (согласовано с митигацией риска R2).
 3. Использование внешнего Cloud SaaS допускается **только** для обезличенных, не содержащих ПДн задач (например, офлайн-эксперименты на синтетике, генерация общих маркетинговых шаблонов) и фиксируется отдельным решением.
 4. Так как online-SLA 200 мс несовместим с генерацией на лету (риск R3), LLM работает в **batch/предвычислении**, что снимает требование к сверхнизкой latency и удешевляет железо.
-

3. ADR

Title: ADR-001. Хостинг LLM для генерации описаний: self-hosted Llama 3 в доверенном контуре (гибрид)

Status: Accepted (2026-07). Заменяет неявное допущение HW-01 об отложенном LLM-слое.

Context: TechnoMart обрабатывает ПДн (ФЗ-152). Бизнес хочет использовать LLM для описаний/объяснений рекомендаций. Online-бюджет 200 мс не позволяет генерировать текст на лету. Собственной DS/DE-команды нет (риск R7). Ранее зафиксирован риск R2 (утечка ПДн через публичную LLM, Exposure 15, стратегия Avoid). Нужно выбрать модель хостинга LLM, не нарушая закон и не ломая экономику проекта.

Decision: Генерация с участием ПДн выполняется на self-hosted Llama 3 70B в доверенном РФ-контуре, в batch-режиме, за PII Sanitizer. Публичный Cloud SaaS допустим только для обезличенных задач по отдельному ADR. Эксплуатацию инференса берёт на себя подрядчик (retainer), пока у заказчика нет своей команды.

Consequences:

Pros: - Соответствие ФЗ-152: ПДн не покидают доверенный контур (закрывает R2). - Предсказуемая стоимость за запрос на объеме; нет утечки бюджета на токены. - Контроль над latency и версионированием модели (поведенческое версионирование). - Vendor independence: нет привязки к одному внешнему провайдеру.

Cons (честные trade-offs): - Выше порог входа: нужен sizing GPU, vLLM/квантование, MLOps-обвязка (детально считаем в HW-07). - Качество ответов Llama 3 в среднем ниже топового проприетарного SaaS — принимаем для нашей узкой задачи. - Зависимость от подрядчика по эксплуатации, пока заказчик не нанял DS/DE (риск R7 переносится в retainer). - CapEx/фикс OpEx на GPU оправдан только при стабильной нагрузке; на очень малых объемах был бы дешевле SaaS.

4. Pitch для СТО (1 абзац)

В наших условиях это единственно верное решение: мы работаем с персональными данными под ФЗ-152, и отправка ФИО, телефонов и адресов во внешний облачный LLM — это прямое нарушение закона и репутационная мина, а не «оптимизация затрат». Self-hosted Llama 3 в доверенном российском контуре с PII-санитизацией оставляет персональные данные под нашим полным контролем, даёт предсказуемую стоимость за запрос на нашем объеме и не привязывает нас к одному вендору. Да, это требует GPU и MLOps-обвязки — но мы и так не можем генерировать текст в онлайн за 200 мс и уходим в batch, поэтому берём дешёвое железо под предсказуемую нагрузку, а эксплуатацию на первое время закрываем подрядным сопровождением. Публичный SaaS мы не выбрасываем — оставляем его для заведомо обезличенных задач, где он реально дешевле и быстрее.