

HW-05

Д3-05. Data Pipelines для системы рекомендаций

Проект «Интеллектуальная система рекомендаций» для Techno-Mart

Системе рекомендаций нужно регулярно обновлять данные о товарах (каталог) и поведении пользователей (клики, покупки). Ниже — источники данных, схема пайплайна (ETL/ELT), выбор хранилищ и подход к Data Governance, обеспечивающий консистентность данных между обучением и онлайн-инференсом.

1. Data Sources

Источники делятся на два класса по характеру поступления данных.

Источник	Тип	Данные	Режим
Сайт (event-трекинг)	Стриминг	view, click, add_to_cart, purchase, search, impression	Непрерывный поток в реальном времени
1C / ERP	Батч	Каталог (SKU, цены, атрибуты), заказы, чеки	Периодическая выгрузка (каталог — раз в сутки, чеки — раз в 15 мин)
Google Analytics	Батч	Историческое поведение за 6–12 мес.	Разовая/периодическая выгрузка


Поведенческие события — высокочастотный поток, поэтому идут через брокер (стрим). Каталог и заказы меняются реже и большими порциями — это классический батч из legacy-систем.

2. Pipeline Design (ETL/ELT)

Применяем **Lambda-архитектуру**: батч-слой даёт полноту и точность исторических признаков, speed-слой — свежесть онлайн-признаков. Подход ELT: сырьё сначала складываем в Data Lake «как есть» (bronze), а очистку и трансформации выполняем

уже внутри пайплайна (silver/gold) — это позволяет переобучать модели на исходных данных при изменении логики.

TechnoMart — Data Pipeline (Lambda-архитектура)



SVG PUML

Где очистка: в Batch Layer (Spark) — дедупликация событий, отбраковка ботов, нормализация SKU и категорий, разрешение идентичности пользователя (склейка cookie/user_id). Результат — слои silver (очищенные) и gold (агрегаты/признаки) в Data Lake.

Где генерация эмбедингов: в отдельном Embedding Job, который читает gold-слой каталога (название, атрибуты, категории) из Data Lake и пишет векторы SKU в Vector DB. Это батч-процесс: эмбединги пересчитываются при обновлении каталога, а не на каждый запрос.

3. Storage Selection

Разным этапам — разные хранилища, под их профиль нагрузки.

Хранилище	Технология	Назначение	Почему именно так
Data Lake	S3 / MinIO (+ формат Parquet, Delta/Iceberg)	Сырьё и промежуточные слои bronze/silver/gold	Дёшево, on-read, хранит исходные данные для переобучения; не нагружает OLTP-базы
Feature Store	Feast (offline: S3/Parquet; online: Redis)	Согласованные признаки для обучения и инференса	Единый источник определений признаков, борьба с Training-Serving Skew
Vector DB	Qdrant	Эмбединги SKU, ANN-поиск похожих товаров	Профиль Vector DB: быстрый поиск ближайших соседей, метаданные-фильтры
Recommendation Store	Redis / KV	Предрассчитанная выдача для online API	Low-latency чтение под SLA 200 мс (см. HW-02)

Сквозной стек: **Kafka** → **Spark (Structured Streaming + Batch)** → **S3 (Data Lake)** → **Feast (Feature Store) + Qdrant (Vector DB)** → **Redis (serving)**. Это прямое продолжение C4 L2 из HW-02, где online-контур только читает готовый результат.

4. Data Governance: консистентность и анти-skew

Главный риск ML-пайплайна — **Training-Serving Skew**: модель обучается на одних признаках, а в проде получает другие (из-за разного кода трансформаций offline и online). Лечится единым Feature Store.

TechnoMart — Feature Store: единый источник признаков (анти-skew)



SVG PUML

Меры обеспечения консистентности:

- **Единые определения признаков.** Признак (например, `purchases_30d`) описывается один раз; и offline-, и online-store материализуются из одних и тех же определений и кода трансформаций.

- **Point-in-time correctness.** При сборке обучающей выборки берутся значения признаков «на момент события», а не текущие — иначе в обучение «протекает» будущее (data leakage).
- **Версионирование данных и датасетов (DVC):** фиксируем, на какой версии данных обучена модель, для воспроизводимости.
- **Data Quality + lineage.** Проверки качества (свежесть, доля null, диапазоны) на входе в Feature Store; прослеживаемость источника каждого признака.

Итог: данные прослеживаются от источника (сайт/1С/GA) до модели, признаки в обучении и проде идентичны, а сырьё в Data Lake позволяет безопасно переобучать модель при изменении логики.