

HW-07

ДЗ-07. Sizing: Llama-3-70B под 1000 RPM

Проект «Интеллектуальная система рекомендаций» для Techno-Mart

В HW-04 принято решение хостить LLM self-hosted (Llama 3) в доверенном контуре. Здесь считаем «железо» и деньги: сколько VRAM нужно модели, сколько и каких GPU потребуется под 1000 запросов в минуту (RPM), сколько это стоит в двух облаках и как оптимизации (квантование, vLLM, батчинг) меняют картину.

Все цифры приближённые (точность расчёта VRAM $\pm 10\text{--}20\%$, цены — иллюстративные на середину 2026). Производительность в токенах/с без бенчмарка точно не считается — используем референсные оценки и обязательно проверяем замером.

1. Hardware Sizing — расчёт VRAM

Формула из лекции: $\text{VRAM} = \text{веса} + \text{KV-кэш} + \text{overhead}$, поверх — запас 15–20 %.

Веса

число параметров $\times$ байт на параметр:

Precision	Байт/параметр	Веса Llama-3-70B
FP16	2	$70 \cdot 10^9 \times 2 = 140 \cdot 10^9 \text{ Б} \approx \mathbf{130 \text{ ГБ}}$
INT8	1	$\approx 65 \text{ ГБ}$
INT4	0.5	$70 \cdot 10^9 \times 0.5 = 35 \cdot 10^9 \text{ Б} \approx \mathbf{35 \text{ ГБ}}$

KV-кэш

Llama-3-70B использует GQA (80 слоёв, 8 KV-голов, head_dim 128), поэтому KV-кэш компактный:

$\text{KV на 1 токен (FP16)} = 2(K,V) \times 80 \text{ слоёв} \times 8 \text{ KV-голов} \times 128 \times 2 \text{ байта} \approx 0.32 \text{ МБ}$

При контексте ~2048 токенов это $\approx 0.64 \text{ ГБ}$ на запрос. Наша задача (описания/объяснения рекомендаций) — короткий контекст, поэтому при батче ~32

одновременных запросов $KV \approx 32 \times 0.64 \approx \sim 20$ ГБ. KV держим в FP16 даже при квантованных весах.

Итог по конфигурациям (веса + KV ~20 ГБ + overhead 1 ГБ + запас 20 %)

Конфигурация	Веса	1. KV + over-head	1. запас 20 %	Сколько влезает
FP16	130 ГБ	~151 ГБ	~180 ГБ	не помещается в 1 GPU → нужен tensor parallelism на 2× A100-80G (160 ГБ) минимум, практичнее 3×
INT4 (AWQ)	35 ГБ	~56 ГБ	~67 ГБ	помещается в 1× A100-80G на одну реплику

Вывод по памяти: квантование INT4 уводит модель с «двух карт на реплику» (FP16) на «одну карту на реплику» — это ключ к экономии.

Выбор типа GPU

GPU	VRAM	Подходит для 70B?
T4	16 ГБ	Нет: даже INT4-веса (35 ГБ) не влезают; пришлось бы шардить на 3+ карты с большими накладными расходами и низкой скоростью
L4	24 ГБ	Нет по той же причине (INT4-веса не помещаются на одну карту)
A100-80G	80 ГБ	Да: INT4 — 1 карта/реплика, FP16 — 2 карты/реплика. Поддерживает Flash/Paged Attention и MIG

T4/L4 предназначены для моделей 7B–13B, а не для 70B. Берём **A100-80G**.

2. Сколько GPU нужно под 1000 RPM

1000 RPM = **~16.7 запросов/с**. Примем средний ответ ~256 выходных токенов.

Пропускную способность считаем по референсным оценкам (с обязательной проверкой бенчмарком):

Режим	Агрегатная throughput на 1× A100-80G	Ёмкость (req/s) при 256 ток	RPM на 1 GPU
Наивно, без батчинга (1 запрос за раз, decode ~40 ток/с)	~40 ток/с	~0.15	~9 RPM
vLLM, Paged + continuous batching (INT4)	~2000 ток/с	~7.8	~470 RPM

- **Без батчинга** под 1000 RPM понадобилось бы ~110 карт A100 — экономически абсурдно.

- **C vLLM (INT4)**: $1000 / 470 \approx 2.1 \rightarrow$ берём **3× A100-80G** (ёмкость ~1400 RPM, есть запас на пики и на HA).
- **FP16 с vLLM**: ниже throughput на карту и 2 карты на реплику $\rightarrow$ под 1000 RPM ориентировочно **2 реплики × 2 GPU = 4–6× A100-80G**.

Вариант	GPU на реплику	Реплик под 1000 RPM	Итого GPU
FP16 + vLLM	2× A100-80G	2–3	4–6× A100-80G
INT4 (AWQ) + vLLM	1× A100-80G	3	3× A100-80G

3. Cloud Selection — стоимость аренды (за месяц)

Берём рекомендованную конфигурацию **3× A100-80G (INT4)**. Цены приближённые, Р/GPU-час, 730 часов/мес.

Провайдер	Р/GPU-час (прибл.)	1 GPU/мес	3 GPU/мес
Yandex Cloud (A100-80G)	~250	~182 500 Р	~547 500 Р
Cloud.ru (A100-80G)	~230	~167 900 Р	~503 700 Р

Для сравнения — FP16-вариант (берём 6× A100-80G):

Провайдер	6 GPU/мес (FP16)
Yandex Cloud	~1 095 000 Р
Cloud.ru	~1 007 400 Р

Точные цены зависят от обязательств (commitment/preemptible), сетевого трафика и дисков — берём из актуальных прайс-листов перед закупкой. Здесь важна методика и порядок величин.

4. Optimization — эффект квантования и vLLM

Оптимизация	Что даёт	Эффект на стоимость
Квантование FP16 → INT4 (AWQ)	Весы 130 → 35 ГБ, 1 карта вместо 2 на реплику, меньше данных по шине (ускорение memory-bound инференса)	GPU-парк ~6 → ~3 карты, ≈ −50 % стоимости
vLLM: Paged Attention + continuous batching	Делает 1000 RPM достижимыми в принципе; непрерывный батчинг держит GPU загруженным, +2–4× throughput против статического батчинга	Без него потребовались бы десятки карт; с ним — единицы
Flash Attention	Быстрее attention без потери качества (A100+)	Дополнительный прирост throughput «бесплатно»

Прогноз экономии: переход с «FP16 без продвинутого батчинга» на «INT4 + vLLM» снижает требуемый парк GPU с ~6 (и более) карт до **3× A100-80G**, то есть месячная стоимость падает примерно вдвое — с ~1 млн ₽ до **~0.5 млн ₽/мес.**

5. Вывод — рекомендованная конфигурация

- **Модель/precision:** Llama-3-70B, **INT4 (AWQ)** — приемлемое качество для шаблонно-генеративных описаний при минимуме VRAM.
- **GPU:** **3× A100-80G** (1 карта на реплику, ёмкость ~1400 RPM с запасом на пики и отказоустойчивость).
- **Движок:** **vLLM** с Paged Attention, continuous batching и Flash Attention.
- **Облако:** **Cloud.ru** как чуть более дешёвый (~503 700 ₽/мес против ~547 500 ₽/мес у Yandex Cloud), при прочих равных; финальный выбор — по SLA, доступности A100 и условиям commitment.
- **Обязательно:** замерить реальную throughput (токенов/с) на целевой конфигурации до фиксации числа реплик — расчёт даёт порядок величины, бенчмарк даёт точку.