

HW-08

ДЗ-08. IaC + CI/CD + MLOps

Проект «Интеллектуальная система рекомендаций» для Techno-Mart

Проектируем автоматизированный конвейер доставки кода и моделей в production: инфраструктура как код, CI/CD-пайплайн, интеграция с переобучением модели (MLOps) и безопасная стратегия релиза (Canary).

1. Infrastructure as Code (Terraform)

Инфраструктура поднимается декларативно. Псевдокод Terraform для ключевых ресурсов (K8s-кластер, GPU node pool под inference, объектное хранилище, vector DB):

Удалённый state (чтобы команда работала с одной версией инфраструктуры)

```
terraform {  
  backend "s3" {  
    bucket = "technomart-tfstate"  
    key    = "prod/infra.tfstate"  
  }  
}
```

Kubernetes-кластер

```
resource "k8s_cluster" "main" {  
  name     = "technomart-prod"  
  version = "1.30"  
}
```

Пул обычных узлов (API, сервисы)

```
resource "k8s_node_pool" "cpu" {  
  cluster = k8s_cluster.main.id  
  size    = "standard-4cpu-16gb"  
  scaling { min = 3, max = 10 }  
}
```

GPU node pool под inference LLM (см. HW-07: A100-80G)

```
resource "k8s_node_pool" "gpu" {  
  cluster = k8s_cluster.main.id  
  gpu_type = "a100-80gb"  
  size     = "gpu-a100-1"
```

```

    scaling    { min = 3, max = 6 }    # 3 реплики под 1000 RPM + запас
    taints     = ["nvidia.com/gpu=present:NoSchedule"]
}

# Объектное хранилище: Data Lake + артефакты моделей
resource "s3_bucket" "data_lake"      { name = "technomart-datalake" }
resource "s3_bucket" "model_registry" { name = "technomart-models" }


# Vector DB (Qdrant) под эмбединги SKU
resource "helm_release" "qdrant" {
  name      = "qdrant"
  chart     = "qdrant/qdrant"
  namespace = "vectordb"
}

```

Принципы: декларативность, удалённый state, переиспользуемые модули, отдельные node pool под GPU (дорогой ресурс — изолируем и масштабируем отдельно).

2. CI/CD Pipeline

TechnoMart — CI/CD + MLOps пайплайн



SVG PUML

Базовый поток кода: Commit -> Build Docker -> Unit Tests -> Deploy to Staging -> E2E Tests -> Deploy to Prod. Между этапами стоят quality gates: сборка/юнит-тесты/security-скан обязаны пройти, иначе пайплайн останавливается. Минимум ручных действий — единственная «ручка» — подтверждение продвижения Canary (опционально автоматизируется).

3. MLOps Integration

Особенность AI CI/CD — три артефакта: код + данные + модель. Конвейер кода связан с переобучением модели через Model Registry:

Обновился датасет -> Airflow Trigger -> Retrain -> Quality Gate -> Model Registry -> Trigger CI/CD (деплой модели)

- **Airflow** оркеструет переобучение по триггеру (новые данные) или расписанию (борьба с дрейфом, риск R4 из HW-01).
 - **Quality gate**: новая модель проходит офлайн-оценку (метрики качества, для RAG — Ragas из HW-06). Не прошла — версия отклоняется, алерт.
 - **Model Registry (MLflow)** хранит версии модели; именно регистрация новой версии триггерит CI/CD на деплой. Это и есть связь «код приложения ↔ артефакт модели».
-

4. Release Strategy — Canary

Деплой и релиз разделены: новая версия сначала выкатывается без трафика, затем трафик переключается постепенно (взвешенная маршрутизация на ingress / service mesh).

TechnoMart — Canary release c rollback



SVG PUMML

Переключение трафика: 1% -> 5% -> 100%, управление весами через ingress/service mesh; на каждом шаге — выдержка под наблюдением.

Метрики отката (rollback triggers):

Метрика	Порог отката
Error rate (5xx, таймауты LLM)	рост выше базовой версии
Latency p99	выше SLO
RAG-качество (Faithfulness / Answer Relevancy)	падение ниже порога
GPU saturation / длина очереди	насыщение, риск деградации

При срабатывании любого триггера — автоматический **rollback** на предыдущую стабильную версию. Для нулевого риска новую модель можно предварительно прогнать в **Shadow mode** (зеркалирование трафика без влияния на ответы пользователю).