

HW-10

Д3-10. FinOps + Governance

Проект «Интеллектуальная система рекомендаций» для Techno-Mart

Аудит этичности и экономической эффективности решения: Model Card для системы и отчёт по оптимизации затрат (FinOps).

Часть 1. Governance — Model Card

Model Card: TechnoMart Recommendation & Description Engine

Model Details

- **Назначение:** персональные рекомендации товаров (behavioral recommender) + генерация описаний/объяснений рекомендаций на self-hosted Llama-3-70B (INT4), RAG поверх каталога.
- **Версия/owner:** v1.x, команда TechnoMart AI (подрядчик на этапе сопровождения).
- **Контур:** доверенный РФ-контур, ПДн не покидают периметр (см. ADR HW-04).

Intended Use & Limitations

- **Intended Use:** подбор и ранжирование SKU, генерация текстовых описаний/объяснений на сайте и в маркетинговых каналах.
- **Out of scope:** не предназначена для кредитного скоринга, ценообразования, юридически значимых решений и любых решений, затрагивающих права человека.
- **Limitations:**
 - cold-start: для новых пользователей/товаров качество ниже (fallback на популярное/контентное);
 - возможны галлюцинации LLM в описаниях — снимаются Output Guardrails и валидацией по каталогу (HW-06);
 - онлайн-SLA 200 мс не позволяет генерировать текст «на лету» — используется предрасчёт/кэш.

Training Data & Bias Analysis

- **Данные:** клики/просмотры/покупки (event-трекинг), история из GA, каталог и чеки из 1С (см. HW-05).
- **Возможные смещения (bias):**

- **popularity bias** — модель усиливает и без того популярные товары, новинки и нишевые SKU недополучают показы;
- **feedback loop** — рекомендации влияют на поведение, которое потом снова обучает модель;
- **смещение по сегментам** — неравномерное качество для регионов/сегментов с малым объёмом данных.
- **Меры:** мониторинг покрытия каталога (coverage), explore/exploit (доля «новых» товаров в выдаче), регулярный пересмотр датасета.

Fairness Metrics

- **Coverage / diversity** выдачи (доля уникальных категорий и товаров).
- **Exposure parity** между сегментами/категориями (нет систематического подавления групп товаров).
- **Качество по сегментам** (precision@k по регионам/категориям не должно резко проседать для меньшинств данных).
- Поскольку система не принимает решений о людях, акцент fairness — на справедливости к товарам/продавцам и отсутствии дискриминации сегментов аудитории.

Ethical considerations & Audit

- Прозрачность: пользователю понятно, что блок — рекомендации; есть объяснение «почему показано».
 - Подотчётность: ведётся Decision/Audit Log (что и на основании каких данных рекомендовано) для разбора инцидентов.
 - Жизненный цикл: Model Card обновляется при каждом значимом изменении модели/данных.
-

Часть 2. FinOps

Пришёл облачный счёт, превысивший бюджет на **+50 %**. Разбираем причины и предлагаем план оптимизации.

Анализ типичных причин перерасхода

Причина	Что произошло	Доля перерасхода (оценка)
Забытые GPU-инстансы	Экспериментальные/ staging GPU (A100) остались включёнными 24/7 после тестов	высокая
Неэффективное хранение логов	Полные prompt/response-логи и трейсы пишутся в «горячее» хранилище без TTL и сэмплинга	средняя
«Слишком умная» модель для простых задач	Llama-3-70B вызывается даже там, где хватает шаблона/маленькой модели/готовой выдачи	высокая
Нет автоскейла вниз	Inference-поды не гасятся в часы низкой нагрузки (ночь)	средняя
Egress / трафик	Неоптимизированная передача данных между зонами	низкая

План Cost Optimization (приоритизация: эффект против сложности)

Мера	Что делаем	Эффект	Сложность
Выключить/тегировать забытые ресурсы	Авто-shutdown по тегам, бюджетные алерты, owner-теги на всех GPU	Высокий	Низкая
TTL и сэмплинг логов	TTL на prompt/response-логи, перенос в «холодное» хранилище, сэмплинг трейсов	Средний	Низкая
Right-sizing модели (каскад)	Простые запросы — шаблон/малая модель/кэш; 70B — только когда реально нужно	Высокий	Средняя
Semantic Cache	Снижение числа вызовов LLM (см. HW-09)	Высокий	Средняя
Квантование INT4 + vLLM	Меньше GPU под ту же нагрузку (см. HW-07, ~ -50 %)	Высокий	Средняя
Spot / preemptible инстансы	Тяжёлый batch-инференс и переобучение — на Spot	Средний	Средняя
KEDA scale-to-zero вне пиков	Гасить поды ночью/в простое (см. HW-09)	Средний	Средняя
Model Distillation	Дистилляция в меньшую модель для частых простых задач	Высокий	Высокая

Быстрые победы (сделать первыми): авто-shutdown забытых GPU + бюджетные алерты, TTL на логи. Дёшево внедрить, быют по самым крупным статьям.

Баланс цены и качества

Ключевой принцип FinOps для AI: **качество модели тоже имеет цену**. Использовать 70B-модель для задачи, где достаточно шаблона или 8B-модели, — это переплата без выигрыша для пользователя. Архитектурный ответ — **каскад моделей** (от дешёвого к дорогому) + семантический кэш: дорогую генерацию запускаем только тогда, когда она действительно повышает ценность.

Телеметрия стоимости

Чтобы перерасход не повторился, в дашборд (HW-06) выведены: **cost per request**, **cost per token**, разбивка по эндпоинтам и (при необходимости) per-tenant attribution. Стоимость отслеживается как NFR с первого дня, а не постфактум по счёту.